通货膨胀影响因素识别*

——基于机器学习方法的再检验

肖争艳　陈　衎　陈小亮　陈彦斌

内容提要：准确识别通货膨胀的影响因素，可以前瞻性地防范通胀风险及其危害，具有重要政策意义。已有研究主要使用SVAR等传统计量方法分析通胀的影响因素，但传统计量方法能够涵盖的因素种类和非线性关系有限。考虑到机器学习方法能够有效突破传统方法的局限，本文综合使用SHAP值解释性方法和SVR等多种非线性机器学习方法，重新识别了2001—2019年间我国所发生的5轮通胀的影响因素。研究结果表明，第一，通胀预期和食品价格上涨是过去20多年间多轮通胀的共同驱动因素；第二，消费和投资等需求拉动因素对通胀的影响逐渐减弱，成本推动因素尤其是劳动力成本对通胀的影响不断增强；第三，货币政策能够通过多种渠道影响通胀走势，并且一直是通胀的重要影响因素。有鉴于此，建议通过加强引导通胀预期、稳定食品生产和供应、营造良好经营环境以缓解劳动成本上涨压力等举措防范通胀风险。此外，不能因为担心通胀压力就过于束缚货币政策的力度，应该在做好金融市场和房地产市场宏观审慎监管的前提下，适当加大货币政策对实体经济的支持力度，以更好地应对我国经济下行压力。

关键词：通货膨胀；机器学习；SHAP值解释性方法；通胀预期

DOI: 10.19343/j.cnki.11–1302/c.2022.06.009

中图分类号：F822.5　　**文献标识码：**A　　**文章编号：**1002–4565(2022)06–0132–16

Identifying the Influencing Factors of Inflation: Reexamination Based on Machine Learning Methods

Xiao Zhengyan　Chen Kan　Chen Xiaoliang　Chen Yanbin

Abstract: Identifying the influencing factors of inflation can help policymakers proactively take measures to prevent inflation risk. Traditional methods such as SVAR are adopted by a lot of literature, but with limited types of factors and non-linear relationships. To solve the limitation, this paper innovatively employs SHapley Additive exPlanations (SHAP) method and several non-linear machine learning methods like SVAR in analyzing the five rounds of inflation that happened in 2001—2019 in China. We have found three main results. Firstly, inflation expectation and food price rise are the driving factors in almost every round of inflation in the past 20 years. Secondly, the impact of demand factors such as consumption and investment gradually diminish, while the influence of cost-driven factors especially labor cost has considerably increased. Thirdly, monetary policy is always a major factor influencing inflation through various channels. Given these results, we can prevent inflation risks by guiding inflation expectation more

*基金项目：国家自然科学基金专项项目“中国特色宏观调控理论研究：规律总结、理论构建与实践应用”（72141306）；国家自然科学基金面上项目“人口老龄化对中国宏观政策有效性的影响：实证研究与模型仿真”（72073141）；国家自然科学基金应急管理项目“国内经济政策环境与金融风险防范”（71850003）。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

effectively, stabilizing the production and supply of foods, creating an enabling business environment to mitigate the rising cost of labor. Moreover, monetary policy should not be constraint by inflation pressure. Under the premise of macro-prudential supervision of financial and real estate markets, the monetary policy should appropriately enhance its support to the real economy to relieve the downward economic pressure in China.

Key words: Inflation; Machine Learning; SHAP Method; Inflation Expectation

一、引言

进入21世纪以来的20多年间，虽然我国的通货膨胀率始终没有超过10%，但是超过3%的温和通货膨胀（下文简称通胀）并不罕见。综合考虑已有研究和政府工作报告的相关表述，本文将经季节调整的CPI环比折年率连续6个月以上超过3%的时期定义为通胀时期（详见下文）。根据这一标准，短短20多年间我国已经发生了5轮通胀，尤其是在经济增速下行时期发生的通胀对货币政策提出了严峻挑战。如果货币政策发力稳增长则会进一步加剧通胀压力，而如果货币政策收紧以应对通胀则会进一步加剧经济下行压力。不仅如此，我国现阶段的经济结构和社会结构使得通胀对中低收入阶层的冲击尤为突出，从而进一步凸显了防范通胀风险的必要性。可见，很有必要对通胀的影响因素进行识别，从而对症下药，更好地防范通胀的危害。

通过梳理文献可知，已经有大量文献尝试探寻我国通胀的影响因素，但是绝大多数已有研究使用的是向量自回归（VAR）和结构向量自回归（SVAR）等传统线性方法，难以将各类因素对通胀的非线性影响考虑在内。同时，传统方法所能涵盖的影响因素数量相对有限，而现实中通胀的影响因素多种多样，不同因素与通胀率之间存在复杂的非线性关系。正因如此，传统线性方法很可能无法全面把握通胀的影响因素及其相对重要性，在此基础上提出的政策建议也很可能面临药不对症的问题。

机器学习方法的不断发展突破了传统方法的局限性，为更好地研究宏观经济问题提供了新的思路。然而，由于机器学习方法本身的解释性较弱（Zhao和Hastie，2021），经济学研究对解释性的要求通常较高，因此在过去较长一段时期里机器学习方法在经济学尤其是宏观经济学领域的应对较为有限，而且已有文献主要聚焦于其在预测维度上的应用，在解释维度上的应用相对较少。机器学习解释性方法的不断发展，为其在解释维度上的应用拓展了空间。第一，解释性方法与传统机器学习方法结合使用，使得机器学习方法可以在解释维度得到更多应用。第二，相比于传统方法，解释性方法可以计算不同变量的重要性大小，从而进一步拓宽了机器学习方法在宏观经济问题中的适用范围。SHAP值解释性方法（SHapley Additive exPlanations）不仅克服了变量替换法和LIME方法（Local Interpretable Model-Agnostic Explanations）等解释性方法在统计性质上存在的一些不足，还能在不损失样本信息的基础上，计算变量在每一个分样本上的重要性大小和影响方向，进而对变量重要性分别进行排序，因此该方法在研究宏观经济问题时具有更广泛的适用空间。

具体到本研究，本文对比各个影响因素在整个样本区间的相对重要性，以及5轮通胀期间影响因素的异同与动态变化。将机器学习方法与SHAP值解释性方法结合使用则可以较好地实现该目标。有鉴于此，本文构建了包含14个指标的基准指标体系和包含31个指标的扩展指标体系，使用多种机器学习方法对2001—2019年间5轮通胀的影响因素及其动态变化进行了全面分析。本文的边际贡献主要体现在两个方面。一是本文较早地将机器学习方法应用到我国通胀影响因素的识别研究，弥补了已有文献在使用传统方法时无法充分考虑各种因素对通胀的非线性影响以及所涵盖的影响因素种类有

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

限等不足。二是本文对2001—2019年间我国所发生的5轮通胀的影响因素进行了对比分析，从而较好地识别出了每轮通胀的主要影响因素及其动态变化，为决策部门前瞻性地防范通胀提供了更有针对性的决策参考。

二、相关文献述评

国内外诸多学术研究通常使用菲利普斯曲线理论模型①研究通胀的形成机制和影响因素。将研究我国通胀影响因素的实证文献与该理论框架对比，可以得到以下几点发现。一是大部分研究考虑了需求拉动和成本推动因素（傅强等，2011；张会清和王剑，2012），通胀预期也日益受到重视（何启志和姚梦雨，2017）。二是“过多的货币追逐过少的商品”是通胀的重要成因，因此需要将货币市场和金融市场因素予以重点考察（张会清和王剑，2012；傅强等，2011；封思贤等，2012）。三是在我国，猪肉和粮食等农产品价格上涨所导致的结构性通胀尤为突出（陈彦斌，2008；高波等，2016），需要将其纳入影响因素范畴。四是在开放市场环境下，输入性因素尤其是能源和农产品等大宗商品价格也会对通胀造成冲击。参考陈彦斌（2008）的做法，可以将国际能源价格的上涨归类为成本推动因素，将国际粮食价格上涨视为国内粮食价格上涨的驱动因素，并将其归类为结构性因素。综上，在研究我国通胀的影响因素时，可以重点考虑需求拉动因素、成本推动因素、结构性因素（含国际输入因素）、金融市场因素和通胀预期5大类因素的影响。事实上，国外文献重点研究的通胀影响因素也被上述5大类因素所涵盖（Bianchi和Civelli，2015）。

如上所述，影响通胀的因素种类繁多，那么究竟哪些因素是通胀的主要影响因素呢？已经有大量文献尝试回答这一问题，多数使用的是VAR和SVAR系列方法、误差修正模型以及分布滞后模型等传统方法。例如，封思贤等（2012）使用VAR方法研究了我国通胀的主要影响因素；傅强等（2011）使用误差修正模型研究了1995—2010年间我国通胀的主要影响因素；高波等（2016）则使用分布滞后模型分析了人民币汇率等因素对通胀的影响。除此之外，还有少数文献使用两区制门限模型（赵进文和丁林涛，2012）、马氏域变向量自回归模型（孟庆斌等，2014）、时变参数向量自回归模型（Bianchi和Civelli，2015）等非线性方法分析了通胀的影响因素。

上述文献对于把握我国通胀的影响因素大有裨益。不过SVAR等传统方法存在一些不足之处，机器学习则突破了传统方法存在的一些局限，有助于更好地识别通胀的影响因素。第一，SVAR等传统方法需要事先给定回归模型的形式以及变量间的结构关系，但机器学习方法尤其是非线性机器学习方法很少对数据分布或模型形式进行过多地约束，而是从数据中学习并挖掘解释变量和被解释变量之间的各种关系，可以比SVAR等传统方法更深入地探寻变量之间的非线性影响（Athey和Imbens，2019），从而得到更加准确更加科学的结果。第二，SVAR等传统方法所能涵盖的影响因素数量相对有限，如果包含的变量太多，会产生模型求解的复杂性与不稳定性（Fan等，2014），机器学习方法的模型框架更加灵活，所能涵盖的变量个数与SVAR等传统方法相比明显增加。第三，SVAR等传统计量方法很少注重对模型拟合性能的验证，与之不同，大多数机器学习方法将样本数据分成训练集和测试集，然后利用其中一部分数据对模型进行估计，并利用另一部分数据对模型的拟合性能进行验证，因此机器学习方法在样本内的拟合和样本外的预测上更有优势。第四，与SVAR等传统方法相比，机器学习方法具有更好的数据驱动特征，能够从数据中挖掘出一些未知的新发现，有助于拓宽经济学的研究范围。

① 根据菲利普斯曲线理论模型，通胀率和失业率之间存在取舍关系，这种取舍关系一方面被用于构建宏观经济学“总需求—总供给”模型中的总供给曲线，另外一方面被用于刻画通胀的产生机制进而预测通胀率。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

除此之外，我国经济结构及其所面临的国际环境不断发生变化，各类因素对通胀的影响很可能也会随之变化，不同轮次通胀的主要影响因素也可能存在显著差异，而已有文献对各类因素的相对重要性及其动态变化的研究有所不足。相比之下，SHAP值方法等机器学习解释性方法在动态分析方面则具有显著优势。有鉴于此，本文将使用多种机器学习方法对2001—2019年间我国所发生的5轮通胀的影响因素进行深入剖析，再使用SHAP值解释性方法对影响通胀的各个因素进行重要性排序，并且计算出各个因素的贡献率及其动态变化，从而识别出各轮通胀的主要影响因素。

三、研究方法介绍和模型构建

（一）基于SHAP值解释性方法的通胀影响因素识别思路

SHAP值解释性方法由Lundberg和Lee（2017）提出，用来解释机器学习模型中每个影响因素对目标预测值的贡献大小。用集合 F 表示所有影响因素的全集或特征集，其中的元素被称为特征，记 $|F|$ 为特征集 F 中元素的个数。机器学习模型 $f(\cdot)$ 在某特定样本点 x_* 上的预测值 $\hat{f}(x_*)$ 可以分解成：

$$\hat{f}(x_*)=\phi_0+\sum_{j=1}^{|F|}\phi_*^j \tag{1}$$

其中，ϕ_0 是模型预测的基准值，一般将预测的均值 $\mathrm{E}[\hat{f}(x)]$ 作为基准值。ϕ_*^j 是第 j 个影响因素在样本 x_* 上对预测的影响大小亦即SHAP值。$|\phi_*^j|$ 越大说明该影响因素对目标预测值的影响越大，$\phi_*^j>0$ 和 $\phi_*^j<0$ 分别表示影响因素；对预测值产生正向或负向影响。第 j 个因素的SHAP值 ϕ_*^j 的计算公式如下：

$$\phi_*^j=\sum_{S\subseteq F\setminus\{j\}}\frac{|S|!(|F|-|S|-1)!}{|F|!}(\upsilon_*(S\cup\{j\})-\upsilon_*(S)) \tag{2}$$

其中，S 是不包含第 j 个因素的集合（集合 F 的子集），给定子集的元素个数 $|S|$，基于特征集 F 一共可以构建 $\sum_{S\subseteq F\setminus\{j\}}\frac{|F|!}{|S|!(|F|-|S|-1)!}$ 个不包含第 j 个因素的子集 S。$(\upsilon_*(S\cup\{j\})-\upsilon_*(S))$ 是在控制变量组合为子集 S 的条件下，因素 j 对预测值的期望影响大小。

机器学习模型 $f(\cdot)$ 训练与预测所使用的影响因素必须一致，通常无法显式地计算出期望 $\upsilon_*(S)$，Štrumbelj和Kononenko（2014）使用蒙特卡洛积分解决了该问题。Aas等（2021）在其基础上结合Nadaraya-Watson估计用于计算 $\upsilon_*(S)$，进一步克服了变量相关性对结果的影响。可以证明，即使影响因素存在相关性的条件下，Nadaraya-Watson估计法计算出的 $\upsilon_*(S)$ 是稳健有效的。为此，本文使用Aas等（2021）的方法计算影响通胀的各个因素在每轮通胀的SHAP值。此外，由于SHAP值的计算是基于已训练的机器学习模型，所以本文计算各个因素在每个样本的SHAP值时仍然利用了所有训练样本的信息。具体的研究思路和计算步骤如下。

首先，假设第 i 轮通胀发生的时间段为 $t\in[T_1,T_N]$，时间区间的长度为 N，该时间段对应的训练样本为 $x^{\mathrm{T}}=\{x_{T_1},x_{T_2},\cdots,x_{T_N}\}$，根据Aas等（2021）的方法计算出 T_n 时刻因素 j 在样本 x_{T_n} 上的SHAP值 $\phi_{T_n}^j$，即 T_n 时刻因素 j 对通胀率的影响大小。

其次，基于因素 j 在第 i 轮通胀区间内每个时刻的SHAP值，得到因素 j 在第 i 轮通胀期间的SHAP值序列 $\phi_i^j=\{\phi_{T_1}^j,\phi_{T_2}^j,\cdots,\phi_{T_N}^j\}$，该序列反映了因素 j 在第 i 轮通胀期间对通胀率的动态影响。进一步地，本文使用该通胀区间上SHAP值序列的均值 $\bar{\phi}_i^j=\frac{1}{N}\sum_{n=1}^{N}\phi_{T_n}^j$，以刻画第 i 轮通胀期间所有时刻因素 j 对通胀的平均贡献。

因为各个通胀影响因素的SHAP值是从预测值分解而来，所以因素 j 的SHAP值 $\phi_{T_n}^j$ 不仅与其在 T_n 时刻对通胀率的影响大小有关，还与 T_n 时刻通胀率的高低有关。物价上升幅度在每轮通胀中各有不同，仅根据SHAP值的大小无法比较特定影响因素在不同轮次通胀中扮演的作用。为了克服上述局限

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

性，本文借鉴VAR模型方差分解的思想，用第 i 轮通胀期间因素 j 的平均SHAP值 $\bar{\phi}_i^j$ 在所有因素的平均SHAP值 $\sum_{j\in F}\bar{\phi}_i^j$ 中所占的比例，刻画因素 j 在第 i 轮通胀期间对通胀率的相对贡献。由此可知，第 i 轮通胀期间因素 j 的贡献率为：

$$Contribution\ Ratio_i^j=\frac{\bar{\phi}_i^j}{\sum_{j\in F}\bar{\phi}_i^j} \tag{3}$$

此外，假设样本区间内一共发生了 I 轮通胀，因素 j 在 I 轮通胀中的SHAP值计算过程与第二步类似，即计算出因素 j 在 I 轮通胀区间中每个样本点的SHAP值，再将所有通胀区间上的SHAP值取平均值，即可得到因素 j 在 I 轮通胀中的SHAP值。

最后，如前文所述，影响通胀的因素可以划分为需求拉动因素等5大类，假设因素 $j_1,j_2,\cdots,j_K$ 同属于某一大类因素 J，大类因素 J 在 T_n 时刻的SHAP值可以表示为 $\phi_{T_n}^J=\sum_{j_k\in J}\phi_{T_n}^{j_k}$。采取与单个因素相似的步骤，可以计算出大类因素 J 对第 i 轮通胀的贡献率。

（二）机器学习模型构建和参数设定

已有文献通常根据新凯恩斯菲利普斯曲线等经典理论，建立通胀率 π_t 与 p 个通胀相关的影响因素 $X_t\in\mathbb{R}^p$ 之间的计量模型 $\hat{\pi}_t=\hat{\beta}X_t+\varepsilon_t$，由此检验各个因素对通胀的影响。机器学习方法在研究通胀问题时，通常构建出基于通胀影响因素的预测函数 $\hat{\pi}_t=f(X_t,\varepsilon_t)$，使用损失函数 $L(\hat{\pi}_t,\pi)$ 度量模型预测通胀率的误差，通过最小化损失函数估计出最优的预测函数 $\hat{f}(X_t,\varepsilon_t)$。相比于传统计量方法，机器学习方法的预测函数更加灵活，从而能够更有效地把握各个影响因素对通胀的影响。本文使用的几种机器学习方法虽然在通胀率的预测函数形式以及训练过程等方面有所不同，但是它们都能在一定程度上识别出通胀率与通胀影响因素之间的关系，进而揭示通胀率的主要影响因素。

结合已有文献的做法，本文主要选择支持向量回归（SVR）、随机森林（RF）、梯度提升（Gradient Boost）、极端梯度提升（XGBoost）和K近邻回归（KNN）5种非线性机器学习方法开展研究。此外，本文还将套索回归（LASSO）、岭回归（Ridge Regression）、弹性网回归（EN）3种常用的线性机器学习方法作为对照，以探寻非线性方法与线性方法的相对优劣。理论上，非线性方法比线性方法更适用于本文研究，因此本部分主要介绍非线性方法。此外在建模过程中，需要使用交叉验证法确定机器学习方法的超参数。参考Tashman（2000）的思路，本文采用滚动交叉验证法确定超参数：将数据集的前50个样本作为滚动预测的基准样本，滚动一步向前预测，并且根据模型滚动预测的效果找出最优模型。

1. SVR方法。

SVR方法在识别通胀的影响因素时，采用的函数形式为 $\hat{\pi}_t=w^{\mathrm{T}}\phi(X_t)+b$。其中，$\phi(\cdot)$ 是对通胀影响因素进行非线性变换的基函数，w 是基函数的权重，基函数变换使得SVR模型可以识别出通胀与影响因素的非线性关系。SVR估计的思想是，最优化各个样本点到支持向量的距离。这使得SVR模型具有了 L_2 惩罚的特点，降低了过拟合和变量多重共线性的负面影响。SVR在损失函数中加入了对误差的容忍度，当SVR预测的通胀率 $\hat{\pi}_t$ 偏离实际通胀率 π_t 超过一定程度时，才将误差记入损失函数中。SVR的目标优化函数：

$$\begin{aligned}&\underset{w,b}{\operatorname{argmin}}\frac{1}{2}\|w\|^2+C\sum_{i=1}^{N}\left(\xi_i+\xi_i^*\right)\\&\text{s.t}\begin{cases}\pi_t-w^{\mathrm{T}}\phi\left(X_t\right)-b\leqslant\varepsilon+\xi_t\\\pi_t-w^{\mathrm{T}}\phi\left(X_t\right)-b\geqslant-\varepsilon-\xi_t^*\\\xi_t\geqslant0,\xi_t^*\geqslant0\end{cases}\end{aligned} \tag{4}$$

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

其中，ε 表示SVR对通胀率预测误差的容忍度，ξ_t 和 ξ_t^* 代表SVR预测误差超过 ε 的部分，被记入损失函数中，C 是超出误差的惩罚大小。SVR的超参数主要有惩罚系数 C 和核函数 $K(X_{t_1}, X_{t_2})$，核函数为经基函数变换后两个样本的内积 $\phi(X_{t_1})^{\mathrm{T}}\phi(X_{t_2})$。本文通过滚动交叉验证法，可以确定前者的最优取值为8，而后者的最优形式为径向高斯核函数（RBF）。

2.基于回归树的集成学习方法（RF、Gradient Boost、XGBoost）。

回归树方法在识别通胀影响因素时，采用的函数形式为 $\hat{\pi}_t = \sum_i \bar{\pi}_{i,t} \cdot I\left(X_t \in R_i\right)$。根据通胀相关的影响因素，将样本空间划分为 i 个不同的区域 R_i，将预测区域的均值作为落入该区域样本的预测值。回归树划分出的区域隐含了通胀各个影响因素与通胀率之间的关系，特别是影响因素之间的交互作用对通胀的影响。本文选择的RF、Gradient Boost、XGBoost三种方法都是基于回归树的集成学习方法，源自Bagging和Boosting的集成思想。虽然三种方法计算过程各有不同，但是对通胀率与通胀影响因素关系的识别本质上与回归树方法相似。

RF方法以Bagging集成方法为基础。Bagging集成方法将多棵回归树的预测结果集成起来，有效提升了模型的预测效果。具体而言，Bagging通过重抽样构造多个不同训练样本从而训练多个机器学习模型，并将所有模型预测的均值作为最终预测值。RF模型在Bagging的基础上进行了改进，RF中的树模型在分裂节点时，会随机选取部分通胀影响因素作为划分区域的节点，从而降低每个模型之间的相似度，以提高模型整体的预测效果和稳健性（Breiman，2001）。RF的超参数主要有回归树的棵数和每棵树节点的个数，本文通过滚动交叉验证可以确定两个超参数的最优取值分别为300和12。

Gradient Boost和XGBoost以Boosting集成方法为基础。Boosting的思想是，通过多次迭代训练多个模型，集成它们的结果，从而提升模型的预测效果。Gradient Boost和XGBoost都是基于Boosting思想的改进方法。其中，Gradient Boost在每次迭代估计中，新模型都会对已有集成模型的预测残差进行拟合，最终实现整体预测损失函数的最小化。在本文中，假设Gradient Boost第 m 次迭代的回归树模型为 $h_m(X_t)$，损失函数为 $L\left(\pi_t, \hat{\pi}_{t,m-1}\left(X_t\right) + v \cdot \beta_m h_m\left(X_t\right)\right) = \left(\pi_t - \hat{\pi}_{t,m-1} - v \cdot \beta_m h_m\left(X_t\right)\right)^2$，$\hat{\pi}_{t,m-1}\left(X_t\right)$ 为第 $m-1$ 次迭代后集成模型根据影响因素样本 X_t 预测的通胀率，v 为正则化模型的学习率。该模型的超参数包括回归树个数、每棵回归树叶节点的深度和学习率，通过滚动交叉验证可知三者的最优取值分别为300、3、0.1。XGBoost改进了Gradient Boost的训练效率，在求解时还利用了损失函数的二阶信息，并且在损失函数 L 中加入了模型复杂度的惩罚项。在本文中，XGBoost优化的损失函数为 $L_m = \sum_{t=1}^{T} g_{tm} h_m\left(X_t\right) + \frac{1}{2} S_{tm} h_m^2\left(X_t\right) + \Omega\left(h_m\right)$，$g_{tm}$ 和 S_{tm} 分别为损失函数 $L\left(\pi_t, \hat{\pi}_{t,m-1}\left(X_t\right) + v \cdot \beta_m h_m\left(X_t\right)\right)$ 关于 $\hat{\pi}_{t,m-1}\left(X_t\right)$ 的一阶导数和二阶导数，惩罚项 $\Omega\left(h_m\right) = \alpha W_m + \frac{\lambda}{2}\left\|\omega_m\right\|^2$ 则是对回归树 $h_m(x)$ 中叶节点的 L_1、L_2 范数进行惩罚。XGBoost模型的超参数相比Gradient Boost多了 α 和 λ 两项惩罚项，通过滚动交叉验证可知本文XGBoost模型的最优回归树个数为300棵，叶节点深度为6，学习率为0.1，α 和 λ 的最优取值均为0.01。

3. KNN方法。

KNN方法基于样本的距离信息来识别通胀影响因素与通胀的关系，其模型形式为 $\hat{\pi}_t = \frac{1}{k} \sum_{X_s \in N_k(X_t)} \pi_S$，即在影响因素构成的空间上，将距离样本 X_t 最近的 k 个样本 $X_s \in N_k\left(X_t\right)$ 对通胀率的预测值 π_s 取平均，作为模型最终的预测值，$N_k\left(X_t\right)$ 为离样本 X_t 最邻近的 k 个样本。虽然KNN方法没有进行参数估计，但是各个样本的距离信息中隐含了通胀率与通胀影响因素的关系，从而使得KNN方法也能有效地识别出二者之间的关系。KNN在计算样本距离时可能会受到多重共线性的影

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

响，但在计算SHAP值的过程中，本文在抽取样本时考虑了变量之间的相关性，使得KNN计算出结果能克服相关性的影响。KNN模型有两个超参数，一是预测时考虑的邻近点个数 k，二是样本点距离的度量方式。本文通过滚动交叉验证法确定，临近点个数 k 的最优取值为2，距离的度量方式为欧式距离。

四、指标体系构建与数据说明

（一）通胀的衡量指标与划分标准

要想研究通胀的影响因素，首先需要对通胀进行测度和衡量。绝大多数文献使用CPI同比增速或者CPI环比增速衡量通胀。CPI环比增速相比CPI同比增速而言不容易受翘尾因素的影响，而且经季节调整的CPI环比折年率更是具有明显的先行特点，能够更加及时准确地反映物价水平的变化趋势（周小川，2013）。因此，本文使用经季节调整的CPI环比折年率作为通胀率的测度指标。

综合考虑经季节调整的CPI环比折年率以及相关影响因素数据的可得性（详见下文），本文将样本区间界定为2001年1月至2019年12月①。在这一时期，我国的通胀率始终没有超过10%，最高点为2007年8月至10月的8.4%左右。纵然如此，中低收入阶层的财产主要以存款的形式存在，对工资的议价能力偏弱，再加上以食品价格上涨为特征的结构性通胀频发，因此哪怕是温和通胀也会对我国经济与社会运行尤其是中低收入阶层的生活带来较大的影响。考虑到2015—2021年间政府工作报告一直将通胀率目标设定为3%左右，而且当通胀率超过3%时，社会各界往往认为我国经济已经面临通胀压力，因此本文将3%设定为通胀率的临界值。与此同时，一般物价水平的“持续上涨”才能称之为通胀，因此本文将经季节调整的CPI环比折年率连续6个月以上超过3%的时期定义为通胀时期。

参照本文对通胀的界定标准，在2001年1月至2019年12月期间，我国一共发生了5轮通胀（图1）。本文不仅要研究5轮通胀各自的影响因素，而且要深入对比5轮通胀的影响因素有何差异以及相关因素的动态变化，因此需要对样本进行切分。简便起见，本文将包含5轮通胀的完整样本区间视为全样本。进一步地，将每一轮通胀时期视为一个分样本，一共包括5个分样本，分别是2003年9月至2004年6月、2006年7月至2008年4月、2009年11月至2011年8月、2012年12月至2013年7月、2019年3月至2019年12月。

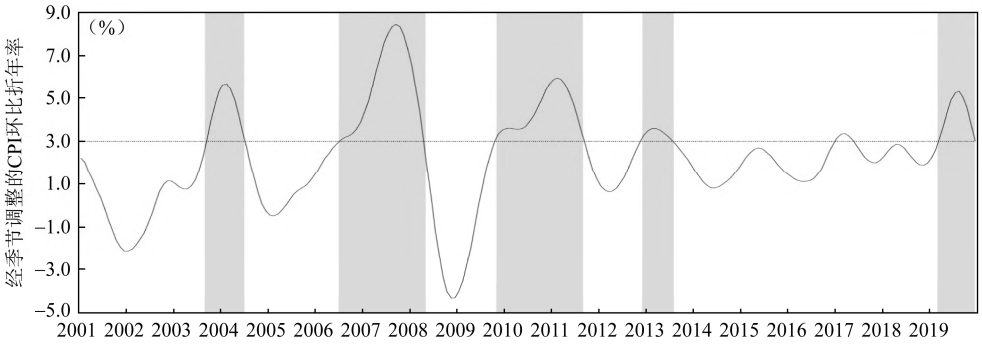

图1　我国通胀率走势以及5轮通胀区间的划分

注：图中的通胀率用经季节调整的CPI环比折年率测度，灰色区域表示的是5轮通胀区间。

① 之所以未考虑2020年，主要原因在于：其一，虽然以CPI同比增速衡量的通胀率在2020年1月至4月仍然高于3%，但是用经季节调整的CPI环比折年率衡量的通胀率在2020年均处于3%以下；其二，2020年受新冠肺炎疫情冲击，大部分指标发生了非正常的剧烈波动，可能会影响机器学习模型的训练效果。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

（二）通胀影响因素的指标体系构建和数据说明

考虑到机器学习方法在处理多变量体系时具有一定优势，本文尽可能地涵盖了文献综述部分所涉及的5大类因素，以构建本文的基准指标体系。具体而言，需求拉动因素包括固定资产投资同比增速、社会消费品零售总额同比增速和出口额同比增速三个指标，分别反映投资需求、国内消费需求和国外消费需求对通胀的影响。成本推动因素包括工业生产者购进价格指数、城镇就业人员单位劳动成本和OPEC原油价格指数三个指标，分别反映原材料成本、劳动力成本和国际能源价格对通胀的影响。结构性因素包括CPI（食品）和联合国粮农价格指数两个指标，分别反映食品价格和国际大宗农产品价格上涨对通胀的影响。金融市场因素包括M2同比增速和银行间7天回购定盘利率这两个与货币政策直接相关的指标，以及上证综合指数、房地产景气指数和人民币实际有效汇率这三个与货币政策间接相关的指标，分别反映货币政策对通胀的直接影响，以及通过股市、房地产市场等渠道对通胀的间接影响。通胀预期因素方面，中国人民银行（下文简称央行）在每个季度专门围绕“物价预期指数”对居民开展调查，这是目前文献中最为常用的指标，本文在基准指标体系中同样使用这一指标衡量通胀预期。上述14个指标构成了本文的基准指标体系①。

上述指标的数据来源于国家统计局、央行、OPEC等机构的官方网站，以及Wind数据库和中经网数据库。为了便于开展实证研究，本文对数据进行了几方面预处理。其一，固定资产投资增速、社会消费品零售总额同比增速和房地产景气指数在个别月份存在缺失值，本文采用三次样条插值法进行了填补。其二，物价预期指数的频率为季度数据，考虑到该指标为存量指标，本文参照张春华等（2017）的做法，采用三次样条插值法将季度数据转化为月度数据。其三，银行间7天回购定盘利率和上证指数只有日度数据，本文将它们的月度平均值作为月度数据的测度指标。其四，从2017年开始，国家统计局将房地产景气指数的基年从2000年调整为2012年，为了保证数据可比性，本文将房地产景气指数的基年统一调整为2000年。此外，本文在建模前对所有指标进行了Z-score标准化处理，以保证训练模型时不受量纲影响。

五、实证结果分析

在进行实证分析之前，首先需要对本文所选取的8种机器学习方法的预测性能进行比较。参考文献的常见做法，选取均方误差(MSE)、平均绝对百分比误差(MAE)和决定系数(R^2)作为模型预测性能的评估指标。通过计算8种方法的评估指标值可以发现②，整体而言非线性方法的预测性能明显优于线性方法，而且KNN、SVR两种非线性方法的预测性能与其他三种非线性方法相比明显占优。因此，本文主要使用KNN和SVR两种方法分析通胀的影响因素。

（一）基于基准指标体系的主要实证结论

本文基于KNN和SVR方法，并使用所设置的基准指标体系，对2001年1月至2019年12月期间我国

①因篇幅所限，基准指标体系构成及描述性统计以附录1展示，见《统计研究》网站所列附件。下同。为了避免多重共线性的影响，本文计算了指标体系中14个指标的VIF值，从结果来看，仅有OPEC原油价格指数、联合国粮农价格指数以及人民币实际有效汇率这3个指标的VIF值大于10，即这3个指标存在一定的共线性关系。不过，这并不会影响本文结果的可靠性。第一，就解释性方法而言，本文选择的Aas等（2021）改进的SHAP值方法能够克服变量间相关性所带来的影响。第二，就本文最终选择使用的机器学习方法而言，KNN方法作为非参数的邻近方法，不涉及模型的训练或者参数的估计，虽然在计算样本距离时共线性可能会产生一定负面影响，但在SHAP值计算阶段，本文在抽取样本时考虑了变量相关性影响，所以指标间的共线性不会影响到KNN模型的计算结果；SVR方法虽然是参数方法，但是其对模型参数进行了L_2惩罚（Hastie等，2009），这大幅减少了指标间的共线性对SVR训练和预测产生的负面影响；此外，本文在滚动交叉验证阶段验证了KNN与SVR方法能够较为准确地对通胀率进行预测，这进一步说明在本文中变量之间的共线性的确不会影响计算结果的稳健性和可靠性。因篇幅所限，各个指标的VIF值以附录2展示。

②因篇幅所限，8种机器学习方法的性能评估指标值以附录3展示。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

所发生的5轮通胀的影响因素进行了全面分析，主要得到了4点结论。

1.每一轮通胀的主要影响因素都存在较为显著的差别。

本文主要从两方面阐述各类因素对通胀的影响。一是根据SHAP值的大小，直接对各类因素进行重要性排序。SHAP值最大的因素排在第1位，表示该因素对通胀的影响是最大的，然后依次类推，得到所有影响因素的相对重要性排序。二是基于所计算的SHAP值，通过式（3）进一步计算得到各影响因素对通胀的贡献率，从而更加直观地得到各种因素对通胀的影响。囿于篇幅限制，正文仅列示了使用KNN方法计算得到的影响因素排序和贡献率大小，分别参见表1和表2。使用SVR方法计算得到的影响因素排序和贡献率大小在附录4展示①。综合分析表1、表2以及附录4可以发现，不管是使用KNN方法还是SVR方法的实证结果，每一轮通胀的主要驱动因素都有所差别。

表1　　KNN方法下各个影响因素对通胀的重要性排序

指标体系	全样本	分样本				
		第一轮	第二轮	第三轮	第四轮	第五轮
通胀预期	1	2	2	1	1	14
CPI（食品）	2	3	4	8	13	1
工业生产者购进价格指数	3	7	3	5	12	7
OPEC原油价格指数	4	11	5	3	8	2
上证综合指数	5	14	1	9	14	6
M2同比增速	6	4	6	10	6	4
单位劳动成本	7	10	12	6	2	3
房地产景气指数	8	6	11	7	3	13
社会消费品零售总额同比增速	9	12	10	2	11	8
联合国粮农价格指数	10	13	9	4	10	10
固定资产投资同比增速	11	1	14	12	7	5
银行间7天回购定盘利率	12	5	7	14	4	9
人民币实际有效汇率	13	8	8	13	9	11
出口额同比增速	14	9	13	11	5	12

表2　　KNN方法下各个影响因素对通胀的贡献率　　（%）

指标体系	全样本	分样本				
		第一轮	第二轮	第三轮	第四轮	第五轮
通胀预期	13.96	18.74	15.44	15.55	22.19	0.60
CPI（食品）	11.03	16.98	8.34	5.66	−4.18	31.78
工业生产者购进价格指数	8.53	7.58	8.75	9.89	−1.92	4.85
OPEC原油价格指数	7.83	0.86	7.79	10.90	6.37	12.26
上证综合指数	7.42	−5.54	15.50	5.48	−10.80	5.22
M2同比增速	7.12	11.92	6.41	4.43	8.97	9.24
单位劳动成本	6.79	3.10	4.06	7.61	20.75	9.84
房地产景气指数	6.45	7.71	5.33	7.34	20.47	1.43
社会消费品零售总额同比增速	6.15	−0.16	5.49	13.43	−0.73	4.37
联合国粮农价格指数	5.85	−0.61	5.87	10.08	3.96	3.60
固定资产投资同比增速	5.64	21.76	1.74	3.19	6.51	7.51
银行间7天回购定盘利率	5.09	7.96	6.28	0.62	12.63	4.02
人民币实际有效汇率	4.53	6.31	6.18	1.55	5.03	2.91
出口额同比增速	3.60	3.38	2.83	4.29	10.75	2.36

① 因篇幅所限，使用SVR方法计算得到的影响因素排序和贡献率大小以附录4展示。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

接下来，本文以KNN方法为例，基于表1和表2的计算结果，并结合我国经济运行的实际情况，详细解释每一轮通胀的主要影响因素及其背后的原因。第一轮通胀期间，在国内和国际因素的共同驱动之下，投资过度状态不断加剧。这期间，固定资产投资同比增速平均而言达到了36.97%，是21世纪前20年间的最高水平，固定资产投资同比增速也因此成为了这一轮通胀的最主要影响因素，贡献率达到了21.76%。第二轮通胀期间，我国股票市场迅猛发展，不少居民将存款从银行搬家到股市，通过财富效应等机制催生了第二轮通胀。这期间，上证综合指数对通胀的贡献率排在第一位，达到了15.50%。为应对2008年国际金融危机的冲击，央行投放了大量流动性，由此引发了第三轮通胀。充裕流动性需要伺机寻找出口，使得公众形成了较强的通胀预期，紧随其后的是我国经济的强劲反弹和居民消费的复苏。通胀预期和社会消费品零售总额同比增速因此成为本轮通胀的主要影响因素，其贡献率分别为15.55%和13.43%。第四轮通胀期间，通胀预期、单位劳动成本、房地产景气指数三大因素起到了主导作用，贡献率分别达到了22.19%、20.75%和20.47%，合计高达63.41%。通胀预期来自国内土地、劳动力等要素价格的上涨以及输入性通胀担忧。劳动力成本上升源自劳动年龄人口供给的不断减少。此外，本轮通胀期间房价平均增速达到了13.4%，这在5轮通胀期间是最高的，也成为了通胀的又一源头。第五轮通胀期间，食品价格（尤其是猪肉价格）是主导因素。受非洲猪瘟和生猪养殖周期性因素的叠加影响，2019年猪肉供给量大幅减少21.3%，导致猪肉价格暴涨。在猪肉价格的强力拉动之下，通胀率快速上行，猪肉价格也因此而成为了第五轮通胀的强劲驱动因素，其贡献率达到31.78%，排名第一。

2.通胀预期和食品价格上涨是大多数轮次通胀的重要影响因素。

进一步对比可以发现，通胀预期和食品价格上涨在大多轮次通胀期间都起到了较为重要的作用。就通胀预期而言，不管是KNN方法还是SVR方法，通胀预期在前4轮通胀中都排名前三位（表3）。相比之下，只有第五轮通胀中通胀预期的排名较为靠后。究其原因，央行为了防范通胀预期扩散，明显地控制了货币政策力度，即便是在经济下行压力较大的情况下也将货币政策保持在了相对偏紧的状态。可以佐证的证据是，2019年第三季度央行货币政策报告专门指出，“注重预期引导，防止通胀预期发散”[①]。事实上，张会清和王剑（2012）基于1998—2011年数据的分析结果表明，通胀预期是最重要的影响因素，这与本文的结果是较为一致的。就CPI食品价格而言，在KNN方法下，CPI食

表3　　两种方法下全样本和分样本排序前五位因素概览

方法	指标体系	全样本	分样本				
			第一轮	第二轮	第三轮	第四轮	第五轮
KNN	通胀预期	1	2	2	1	1	14
	CPI（食品）	2	3	4	8	13	1
	工业生产者购进价格指数	3	7	3	5	12	7
	OPEC原油价格指数	4	11	5	3	8	2
	上证综合指数	5	14	1	9	14	6
SVR	通胀预期	1	3	2	1	2	13
	CPI（食品）	2	2	3	7	13	1
	上证综合指数	3	14	1	8	14	6
	OPEC原油价格指数	4	11	4	4	8	3
	单位劳动成本	5	9	11	6	4	2

① 资料来源：《中国货币政策执行报告（二〇一九年第三季度）》，中国人民银行货币政策分析小组，2019年11月15日。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

品价格的贡献率在第一轮、第二轮和第五轮通胀过程中均排名前五位，CPI食品价格的贡献率在全样本排在第二位。结合表3可以发现，不管是KNN方法还是SVR方法，通胀预期与CPI食品价格都是通胀的重要影响因素。而且，两种方法下通胀预期与CPI食品价格在全样本的贡献率均排在前两位。

3.需求拉动因素的影响有所减弱，成本推动因素的影响有所增强，并且伴随着时间的推移，成本推动因素的贡献率已经明显高于需求拉动因素的贡献率。

表4列示了消费、投资和出口三大需求对通胀的贡献率及其动态变化趋势，从中可以得到两点主要发现。第一，整体而言，三大需求因素对通胀的贡献率相对偏低。以KNN方法计算的结果为例，在全样本中，消费、投资和出口对通胀的贡献率分别为6.15%、5.64%和3.60%，在基准指标体系所考察的14种因素中分别排名第9、11和14位。其中，投资主要是在第一轮通胀起到了较为重要的作用，消费和出口分别在第三轮和第四轮通胀起到了较为重要的作用。但是，在其他轮次通胀，三种需求因素的影响相对偏弱。第二，从动态视角来看，需求拉动因素对通胀的影响呈现减弱态势。不管是KNN方法还是SVR方法的结果，在第一轮通胀期间需求拉动因素贡献率之和都达到了25%左右，此后4轮通胀期间需求拉动因素的贡献率之和均低于这一水平，而且第三、四、五轮通胀期间需求拉动因素贡献率的下降趋势较为明显。

表4　两种方法下需求拉动因素对通胀贡献率的动态演化　（%）

方法	指标体系	全样本	分样本				
			第一轮	第二轮	第三轮	第四轮	第五轮
KNN	固定资产投资同比增速	5.64	21.76	1.74	3.19	6.51	7.51
	社会消费品零售总额同比增速	6.15	–0.16	5.49	13.43	–0.73	4.37
	出口额同比增速	3.60	3.38	2.83	4.29	10.75	2.36
	需求拉动因素合计	15.40	24.98	10.06	20.91	16.53	14.24
SVR	固定资产投资同比增速	5.91	21.12	1.86	3.91	6.43	8.80
	社会消费品零售总额同比增速	5.51	0.65	4.56	12.23	–1.14	4.14
	出口额同比增速	3.90	3.89	3.64	5.20	4.02	2.34
	需求拉动因素合计	15.32	25.67	10.06	21.34	9.32	15.27

表5列示了工业生产者购进价格指数、单位劳动成本和OPEC原油价格指数三类成本因素对通胀的贡献率及其动态变化，从中可以得到几点发现。第一，整体而言，成本推动因素对通胀的贡献率明显超过需求拉动因素。就全样本而言，在KNN方法和SVR方法之下，三类成本推动因素对通胀的贡献率之和都超过了20%，而需求拉动因素的贡献率之和仅略高于15%。第二，从动态视角来看，成本拉动因素对通胀的贡献率有所增强。在KNN方法之下，成本推动因素在第一轮通胀期间的贡献率仅为11.54%，第二轮通胀期间升至20.60%，第三轮到第五轮通胀期间则均超过了25%。在SVR方法之下，成本推动因素的贡献率则从第一轮通胀期间的11.61%升至第五轮通胀期间的27.60%。第三，劳动力成本对通胀的影响呈现出明显的强化态势。KNN方法和SVR方法的计算结果均表明，单位劳动成本的贡献率从第一轮通胀期间的4%以下升高到了第五轮通胀的10%左右。事实上，张会清和王剑（2012）等研究也发现，成本因素尤其是劳动力成本对通胀的影响不断加强，这与本文的结论是一致的。

4.货币政策不仅会对通胀产生较强的直接影响，还会通过股市、房地产等渠道间接影响通胀，其整体影响一直处于重要地位。

金融市场的指标大部分直接或间接地与货币政策相关。其中，M2同比增速和银行间7天回购定

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

盘利率与货币政策直接相关。此外，上证综合指数和房地产景气指数与货币政策间接相关，分别能够反映货币政策通过股市和房地产市场对通胀所产生的间接影响。在开放经济条件下，汇率变化与货币政策操作也是息息相关的，进而会对通胀产生影响。上述5种因素对通胀的影响详见表6，从中可以得到如下主要发现。

表5　两种方法下成本推动因素对通胀贡献率的动态演化　（%）

方法	指标体系	全样本	分样本				
			第一轮	第二轮	第三轮	第四轮	第五轮
KNN	工业生产者购进价格指数	8.53	7.58	8.75	9.89	–1.92	4.85
	单位劳动成本	6.79	3.10	4.06	7.61	20.75	9.84
	OPEC原油价格指数	7.83	0.86	7.79	10.90	6.37	12.26
	成本推动因素合计	23.15	11.54	20.60	28.39	25.20	26.96
SVR	工业生产者购进价格指数	6.48	6.28	7.56	4.70	3.25	2.33
	单位劳动成本	7.31	3.90	4.51	8.46	12.18	12.94
	OPEC原油价格指数	7.95	1.43	8.28	10.44	4.63	12.33
	成本推动因素合计	21.74	11.61	20.35	23.59	20.07	27.60

表6　两种方法下金融市场因素对通胀贡献率的动态演化　（%）

方法	指标体系	全样本	分样本				
			第一轮	第二轮	第三轮	第四轮	第五轮
KNN	M2同比增速	7.12	11.92	6.41	4.43	8.97	9.24
	银行间7天回购定盘利率	5.09	7.96	6.28	0.62	12.63	4.02
	上证综合指数	7.42	–5.54	15.50	5.48	–10.80	5.22
	房地产景气指数	6.45	7.71	5.33	7.34	20.47	1.43
	人民币实际有效汇率	4.53	6.31	6.18	1.55	5.03	2.91
	金融市场因素合计	30.62	28.36	39.70	19.41	36.30	22.82
SVR	M2同比增速	6.80	11.04	5.88	4.40	12.87	8.27
	银行间7天回购定盘利率	4.70	8.15	6.37	–0.02	10.47	3.27
	上证综合指数	8.04	–4.99	16.44	6.16	–11.75	5.24
	房地产景气指数	7.29	7.72	5.40	8.98	29.84	0.78
	人民币实际有效汇率	3.22	6.01	4.34	0.13	4.30	2.05
	金融市场因素合计	30.05	27.93	38.44	19.66	45.73	19.61

一是，M2同比增速和银行间7天回购定盘利率这两个与货币政策直接相关的因素对通胀有着较强的影响。不管是KNN方法还是SVR方法，在本文所考察的全样本上，M2同比增速和银行间7天回购定盘利率的贡献率之和都达到了12%左右，与通胀预期的影响相差无几（参见表2和附录3）。从5轮通胀期间的表现来看，两个因素除了在第三轮通胀期间的贡献率偏低，在其他4轮通胀期间都对通胀产生了较为重要的影响。这一实证发现与高波等（2016）的研究结论有相似之处，他们同样发现货币政策是我国物价变动的主要因素。

二是，上证综合指数、房地产景气指数等与货币政策间接相关的因素对通胀的影响不容忽视。在KNN方法和SVR方法之下，全样本中的上证综合指数和房地产景气指数对通胀的贡献率之和分别达到了13.87%和15.33%，超过了M2同比增速和银行间7天回购定盘利率对通胀的贡献率。可见，在分析货币政策对通胀的影响时，不应该忽视上证综合指数和房地产景气指数这两个指标。事实上，股票价格和房地产价格的波动均隐含了未来通胀的信息。此外，人民币汇率变动的影响整体较为稳定，不管是对KNN方法还是对SVR方法而言，人民币实际有效汇率在全样本中的贡献率均低于5%。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

三是，将货币政策对通胀的直接影响，及其通过股市、房地产市场和汇率市场对通胀的间接影响考虑在内可以发现，货币政策对通胀的整体影响一直处于重要地位。本文将货币政策的直接影响和间接影响进行加总，以得到货币市场对通胀的总体影响，并且参照封思贤等（2012）做法将其称为金融市场因素的影响，具体参见表7。KNN方法和SVR方法的计算结果双双显示，在全样本之下，金融市场因素对通胀的贡献率均超过30%，是本文考察的所有5大类因素当中贡献率最高的一类因素。具体到每一轮通胀，金融市场因素的贡献率最低也接近20%，最高则达到了45.73%，该类因素对通胀的影响可见一斑。

表7　两种方法下5大类因素对通胀贡献率的对比分析　（%）

方法	指标体系	全样本	分样本				
			第一轮	第二轮	第三轮	第四轮	第五轮
KNN	需求拉动因素	15.40	24.98	10.06	20.91	16.53	14.24
	成本推动因素	23.15	11.54	20.60	28.39	25.20	26.96
	结构性因素	16.88	16.37	14.20	15.74	–0.22	35.38
	金融市场因素	30.62	28.36	39.70	19.41	36.30	22.82
	通胀预期	13.96	18.74	15.44	15.55	22.19	0.60
SVR	需求拉动因素	15.32	25.67	10.06	21.34	9.32	15.27
	成本推动因素	21.74	11.61	20.35	23.59	20.07	27.60
	结构性因素	18.70	18.20	15.77	19.20	2.53	35.76
	金融市场因素	30.05	27.93	38.44	19.66	45.73	19.61
	通胀预期	14.20	16.59	15.38	16.20	22.36	1.76

（二）基于扩展指标体系的稳健性检验结果①

本文的基准指标体系一共包括了14个指标，而封思贤等（2012）等使用VAR和SVAR等传统方法通常只考察了5个左右变量。与之相比，本文的基准指标体系已经较为丰富。不过，与Hou等（2020）、Ng（2014）等文献使用机器学习方法研究其他问题时所考察的数十个甚至上百个指标相比，本文基准指标体系所涵盖的指标数量偏少。这主要是为了兼顾模型的准确性和可解释性。正如Bau等（2017）和James等（2013）等文献所述，不少机器学习方法为了追求模型的复杂性和预测准确性，很大程度上牺牲了模型的可解释性，导致机器学习成为“黑箱模型”。为了兼顾模型的准确性和可解释性，本文基于经济学理论和国内外经验研究构建了适度规模的基准指标体系，这样能够更好地把握每一个因素对通胀的影响机理，从而提高计算结果的可解释性。

在兼顾模型准确性和可解释性的前提下，本文进一步构建了包含31个指标的扩展指标体系，从而更充分地体现机器学习方法的优越性。扩展指标体系的所有指标仍然隶属于需求拉动因素、成本推动因素、结构性因素、金融市场因素和通胀预期5大类。与基准指标体系相比，需求拉动因素主要增加了房地产投资同比增速、居民收入信心调查指数、港口货物吞吐量同比增速等指标；成本推动因素主要增加了求人倍率、CRB现货指数、PPIRM（燃料）、PPIRM（黑色金属）、PPIRM（建筑材料）等指标；结构性因素主要增加了CPI（肉类）、CPI（鲜菜）、CBOT（大豆）、CBOT（小麦）等指标；金融市场因素主要增加了M1同比增速、1~5年期贷款基准利率、深证综合指数、房价增长率、人民币兑美元汇率中间价、人民币兑欧元汇率中间价、人民币兑日元汇率中间价等指标；通胀预期

① 除了构建扩展指标体系，本文还对部分重要指标的测度方式进行替换，并进行稳健性检验。结果表明，本文的核心结论依然成立。因篇幅所限，相关结果以附录 5 展示。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

仍然用物价预期指数衡量。扩展指标体系的数据来源和数据预处理思路与基准指标体系保持一致①。为了保证训练模型时不受量纲影响，本文在进行稳健性检验之前，同样对相关指标进行了标准化处理。

稳健性检验结果显示，在使用扩展指标体系之后，本文的主要结论仍然成立。第一，通胀预期与食品价格是多轮通胀的重要因素。如表8所示，不管使用KNN方法还是SVR方法，通胀预期在前4轮通胀中都起到了重要作用，其中在前三轮通胀期间的排序全部在前三位，而食品价格对通胀的影响在第一轮、第二轮、第五轮通胀期间非常突出。对全样本而言，通胀预期对通胀的影响在31个指标中排名第一位，食品价格的贡献率在用KNN方法计算时高居第二位，用SVR方法计算时也排在了前5位，由此能够进一步凸显通胀预期和食品价格对多轮通胀的共同驱动作用。这些结果与上文的基准结果较为一致。

表8　　扩展指标体系下通胀预期和食品价格的贡献率

影响因素类别	方法类别	指标	全样本	分样本				
				第一轮	第二轮	第三轮	第四轮	第五轮
通胀预期	KNN	排序	1	2	3	2	7	29
		贡献率（%）	7.35	11.81	7.65	8.46	5.82	–0.95
	SVR	排序	1	3	3	2	4	30
		贡献率（%）	8.49	10.62	9.38	10.28	9.46	–1.67
食品价格	KNN	排序	2	3	3	28	29	1
		贡献率（%）	6.18	11.32	10.93	–0.89	–3.51	15.93
	SVR	排序	5	7	4	28	29	1
		贡献率（%）	5.49	8.48	10.89	–0.88	–4.59	14.49

注：食品价格的贡献率是扩展指标体系下CPI食品价格、CPI肉类价格、CPI鲜菜价格三个指标的贡献率之和，食品价格的排序则是三个指标贡献率之和在所有扩展指标中的排序。

第二，从动态视角来看，需求拉动因素对通胀的贡献率呈现下降趋势，而成本推动因素的贡献率则呈现明显增强的趋势。如表9所示，从第一轮通胀到第五轮通胀，不管是KNN方法还是SVR方法的计算结果，需求拉动因素对通胀的贡献率都下降了超过10个百分点，而成本推动因素对通胀的贡献率则上升了超过10个百分点。伴随着时间的推移，成本推动因素的贡献率同样已经明显高于需求拉动因素的贡献率。以第五轮通胀为例，KNN方法和SVR方法的计算结果显示，成本推动因素的贡

表9　　扩展指标体系下5大类影响因素的贡献率　　（%）

方法类别	影响因素类别	全样本	分样本				
			第一轮	第二轮	第三轮	第四轮	第五轮
KNN	需求拉动因素	22.11	30.93	19.48	24.73	15.53	17.54
	成本推动因素	22.66	18.23	17.13	29.98	15.37	33.13
	结构性因素	15.82	22.21	13.56	12.55	22.43	21.15
	金融市场因素	32.05	16.82	42.17	24.28	40.85	29.13
	通胀预期	7.36	11.81	7.65	8.46	5.82	–0.95
SVR	需求拉动因素	23.17	38.16	18.23	25.22	17.94	20.35
	成本推动因素	19.53	13.96	15.12	22.86	28.38	29.77
	结构性因素	14.85	18.73	14.28	11.69	18.80	17.96
	金融市场因素	33.96	18.53	42.99	29.95	25.42	33.59
	通胀预期	8.49	10.62	9.38	10.28	9.46	–1.67

① 因篇幅所限，扩展指标体系的构成及其描述性统计以附录 6 展示。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

献率平均而言比需求拉动因素高出了12.5个百分点。这些稳健性检验结果与表4和表5的基准结果同样高度一致。

第三，将货币政策对通胀的直接影响和间接影响综合考虑在内可以发现，金融市场因素对5轮通胀都产生了重要影响。从表9可以发现，对全样本而言，金融市场因素对通胀的贡献率高达33%左右，在5大类因素中排名第一位。对5个分样本而言，金融市场因素的最低贡献率也达到了16.82%，最高贡献率更是达到了42.99%，由此足见金融市场因素对通胀的影响之大。这一结论与表6的基准结果高度一致。

六、结论与政策启示

本文综合使用多种非线性机器学习方法，重新检验了需求拉动因素、成本推动因素、结构性因素、金融市场因素和通胀预期5大类因素对2001—2019年期间我国所发生的5轮通胀的影响大小及其动态变化。研究结果表明，第一，在识别通胀的影响因素时，非线性机器学习方法的预测性能显著优于线性机器学习方法，其中KNN、SVR两种方法的预测性能尤为突出。第二，通胀预期和结构性因素（尤其是食品价格上涨）是过去20多年间我国所发生的多轮通胀所共有并且较为重要的驱动因素。第三，消费和投资等需求拉动因素对通胀的影响逐渐减弱，成本推动因素尤其是劳动力成本对通胀的影响则不断增强，而且伴随着时间的推移，成本推动因素的贡献率已经超过需求拉动因素的贡献率。第四，货币政策不仅会对通胀产生较强的直接影响，还会通过股市、房地产等渠道间接影响通胀，综合考虑直接影响和间接影响之后发现，货币政策在过去20多年间一直是我国通胀的重要影响因素。

基于上述实证结论，本文认为要更好地防范通胀风险，促进经济平稳发展，需要决策部门重点做好如下几方面工作。第一，央行等政府决策部门应该继续注重对公众通胀预期的引导，以防范通胀预期所带来的通胀压力。第二，通过加大补贴等方式提高农户积极性，积极防范各类疫情、病情对食品供给的冲击，从而保证食品供给和食品价格平稳运行，从供给端缓解通胀压力。第三，我国老龄化进程正在不断加快，由此带来的劳动力数量减少和劳动力成本上升态势或将更加严重，需要通过进一步降低税负、削减融资成本、拓宽融资渠道等方式优化企业经营环境，从而缓解劳动力成本上涨对供给的影响以及由此带来的通胀压力。第四，在做好金融市场和房地产市场审慎监管的前提下，适当加大货币政策力度以应对经济下行压力。不能仅为了防范通胀风险而束缚了货币政策的手脚，而应该在做好金融和房地产市场审慎监管以及切实保障农产品平稳生产和供应的前提下，适当加大货币政策力度以应对当前我国经济面临的下行压力，更好地实现经济稳定和金融稳定的双重目标。

参考文献

[1] 陈彦斌. 中国当前通货膨胀形成原因经验研究: 2003—2007年[J]. 经济理论与经济管理, 2008(2): 16–22.
[2] 封思贤, 蒋伏心, 谢启超, 等. 金融状况指数预测通胀趋势的机理与实证: 基于中国1999—2011年月度数据的分析[J]. 中国工业经济, 2012(4): 18–30.
[3] 傅强, 朱映凤, 袁晨. 中国通货膨胀主要影响因素的判定与阐释[J]. 中国工业经济, 2011(5): 5–15.
[4] 高波, 徐涛, 刘江帆, 等. 我国物价的影响因素及中期发展趋势分析[J]. 金融发展评论, 2016(5): 91–111.
[5] 何启志, 姚梦雨. 中国通胀预期测度及时变系数的菲利普斯曲线[J]. 管理世界, 2017, 33(5): 66–78.
[6] 孟庆斌, 靳晓婷, 吴蕾. 我国通货膨胀影响因素的非线性影响效应分析[J]. 金融研究, 2014(4): 30–46.
[7] 张春华, 高铁梅, 陈飞. 经济时间序列频率转换方法的研究与应用[J]. 统计研究, 2017, 34(2): 92–100.
[8] 张会清, 王剑. 我国通胀演变的决定因素与传导机制研究[J]. 财贸经济, 2012(2): 98–105.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

[9] 赵进文，丁林涛. 通货膨胀的宏观经济影响因素分析[J]. 统计研究, 2012, 29(12): 69–76.
[10] 周小川. 分析物价趋势的指标选择[J]. 金融研究, 2013(5): 1–11.
[11] Aas K, Jullum M, Løland A. Explaining Individual Predictions when Features are Dependent: More Accurate Approximations to Shapley Values[J]. Artificial Intelligence, 2021(9): 1–24
[12] Athey S, Imbens G W. Machine Learning Methods that Economists Should Know About[J]. Annual Review of Economics, 2019(11): 685–725.
[13] Bau D, Zhou B, Khosla A, et al. Network Dissection: Quantifying Interpretability of Deep Visual Representations[A]. The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)[C]. 2017: 6541–6549.
[14] Bianchi F, Civelli A. Globalization and Inflation: Evidence from a Time-varying VAR[J]. Review of Economic Dynamics, 2015, 18(2): 406–433.
[15] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5–32.
[16] Fan J, Han F, Liu H. Challenges of Big Data Analysis[J]. National Science Review, 2014, 1(2): 293–314.
[17] Hou K, Xue C, Zhang L. Replicating Anomalies[J]. The Review of Financial Studies, 2020, 33(5): 2019–2133.
[18] Hastie T, Tibshirani R, Friedman J H, et al. The Elements of Statistical Learning: Data Mining, Inference, and Prediction[M]. New York: Springer, 2009.
[19] James G, Witten D, Hastie T, et al. An Introduction to Statistical Learning with Applications in R[M]. New York: Springer Text in Statistics, 2013.
[20] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions[A]. Advances in Neural Information Processing Systems[C]. 2017: 4765–4774.
[21] Ng S. Boosting Recessions[J]. Canadian Journal of Economics, 2014, 47(1): 1–34.
[22] Štrumbelj E, Kononenko I. Explaining Prediction Models and Individual Predictions with Feature Contributions[J]. Knowledge and Information Systems, 2014, 41(3): 647–665.
[23] Tashman L J. Out-of-sample Tests of Forecasting Accuracy: An Analysis and Review[J]. International Journal of Forecasting, 2000, 16(4): 437–450.
[24] Zhao Q, Hastie T. Causal Interpretations of Black-box Models[J]. Journal of Business & Economic Statistics, 2021, 39(1): 272–281.

作者简介

肖争艳，中国人民大学应用统计科学研究中心研究员，中国人民大学统计学院教授、博士生导师。研究方向为金融计量、风险管理与非寿险精算。

陈衎，中国人民大学统计学院博士研究生。研究方向为机器学习方法与大数据分析。

陈小亮（通讯作者），中国社会科学院经济研究所副编审。研究方向为经济增长与宏观经济政策。电子邮箱: chenxiaoliang2200@126.com。

陈彦斌，中国人民大学经济学院教授、博士生导师。研究方向为中国宏观经济学理论和宏观政策评价。

(责任编辑: 都田秀佳)

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net